数据分析第一次作业

1. 实现均值,方差,分位数的计算

a,均值计算,函数参数为可变参数。数据源为:nums = range(1, 21)

```
def cal_mean(*nums):
    sum = 0
    for i in nums:
        sum += i
    mean = sum / len(nums)
    return mean
```

执行结果为:10.5

b,方差计算 函数为可变参数 数据源不变

```
def cal_var(*nums):
    mean = cal_mean(*nums)
    sumvar = 0
    for j in nums:
        sumvar += (j - mean) ** 2
    var = sumvar / len(nums)
    return var
```

执行结果为:33.25 c,分位数计算

```
def cal quantile(n,*nums):
   #分位数的个数
   #从列表上里边随机抽取ran count个数
   ran count = 10
   if ran count < len(nums):</pre>
       samlist = rd.sample(list(nums), ran count)
   else:
       return
   #对随机数进行排序
   sortlist = np.sort(samlist)
   lens = len(sortlist)
   part = (sortlist[lens - 1] - sortlist[0]) / n
   list quantile = []
   x += sortlist[0] + part
   list quantile.append(x)
       x += part
       list quantile.append(x)
   return sortlist,part,list_quantile
```

其中 part 为每一个区间的长度,list_quantile 为保存分位点的数组,由于数据源是随机抽取的,所以每次的执行结果都不尽一样

程序结果为:[7.0 13.0]程序测试函数如下:

```
pif __name__ == "__main__":
    nums = range(1, 21)
    # print(cal_mean(*nums))
    # print(cal_var(*nums))
    print(cal_quantile(3,*nums))
```

- 2. 实现两种噪声数据过滤,和缺失值补全方法
 - 1.等箱装箱平滑(中位数光滑),每个箱子的宽度都是一样的

```
#等宽平滑

def equal_bins():
    nums = [7,9,11,5,6,12,3,2,13,14,18,20,22]
    sorted_nums = sorted(nums)
    lens = len(sorted_nums)
    # n 表示每个箱子的宽度
    n = 3
    # 箱子的数量
    count_bin = (sorted_nums[lens - 1] - sorted_nums[0]) / n
    real_countbin = int(count_bin + 1)
    i = 0
    var = 0
    m = 0
    list = []
    # [2, 3, 5, 6, 7, 9, 11, 12]

for x in range(real_countbin):
    if var <= lens - 1:
        m = sorted_nums[var] + n
        while var <= lens - 1 and sorted_nums[var] <= m:
        list.append(sorted_nums[var])
        var += 1
        print(list, "中位数光滑之后为:%d" % np.median(list))
    list = []
```

程序执行结果为(其中每个箱子的宽度是 n = 3):

```
[2, 3, 5] 中位数光滑之后为:3
[6, 7, 9] 中位数光滑之后为:7
[11, 12, 13, 14] 中位数光滑之后为:12
[18, 20] 中位数光滑之后为:19
[22] 中位数光滑之后为:22
```

2. 等频装箱平滑(均值光滑)

```
#等频平滑

def equal_frequency():
    nums = [47,81,21,74,78,98,94,56,56,78,94,65,1,23,29,78,26]
    lens = len(nums)
    #假定每个箱子里边的数量是4个
    n = 5
    sortnums = sorted(nums)
    #箱子数量 判断余数是否大于零点五,以便于决定加一后四舍五入或者直接四舍五入
    bin_num = lens / n
    remain = lens % n
    if remain > 0:
        bin_num += 1
    i = 0

for x in range(int(bin_num)):
    print(sortnums[i:i+n])
    print("第%d个箱子的均值光滑后的数值为:%.2f" % (x+1,np.mean(sortnums[i:i+4])))
    i += n
```

执行结果为(用均值代替光滑后的数值):

```
[1, 21, 23, 26, 29]
第1个箱子的均值光滑后的数值为:17.75
[47, 56, 56, 65, 74]
第2个箱子的均值光滑后的数值为:56.00
[78, 78, 78, 81, 94]
第3个箱子的均值光滑后的数值为:78.75
[94, 98]
第4个箱子的均值光滑后的数值为:96.00
```

1.均值补全缺失值

2. 启发式补全

```
#启发式的补全
def missvalue process2():
    #1代表男生 0代表女生 最后两个数值缺失
    sex_height = [[0,1,0,1,0,1,0,1],[161,175,155,174,163,180,0,0]]
   sexs = sex_height[0]
   heights = sex_height[1]
    location_man = []
    location women = []
    for i in range(len(sexs) - 2):
       if sexs[i] == 1:
           location_man.append(i)
            location_women.append(i)
    #统计男生身高
       hei man += heights[j]
       hei women += heights[m]
    #女生平均身高
   heights[7] = man_mean
   heights[6] = women_mean
   return heights
```

执行结果为:

```
[161, 175, 155, 174, 163, 180, 159.67, 176.33]
```

最后两个为补全之后的数值

3. 实现两种数据离散化,数据数值化,数组归一化方法

```
数据离散化的方法(连续型数据离散化)

1.等箱法 每个箱子的宽度一样

2.等频法 每个箱子里边的数量是一样的
"""
```

1, 等箱法

执行结果:

```
[2, 5]
[6, 9]
[11, 12, 13, 13, 14]
[18, 19, 20]
[22]
```

2.等频法

```
def equal_frequency():
    nums = [17,81,21,44,78,98,94,56,56,78,94,45,1,23,29,78,26]
    lens = len(nums)
    #假定每个箱子里边的数量是4个
    n = 4
    sortnums = sorted(nums)
    #箱子数量 判断余数是否大于零点五,以便于决定加一后四舍五入或者直接四舍五入
    bin_num = lens / n
    remain = lens % n
    if remain > 0:
        bin_num += 1
    i = 0
    for x in range(int(bin_num)):
        print(sortnums[i:i+n])
        print("第%d个箱子的类标记为:%.2f" % (x+1,np.mean(sortnums[i:i+4])))
        i += n
```

执行结果:

```
[26, 29, 44, 45]
第2个箱子的类标记为:36.00
[56, 56, 78, 78]
第3个箱子的类标记为:67.00
[78, 81, 94, 94]
第4个箱子的类标记为:86.75
[98]
第5个箱子的类标记为:98.00
```

```
数据标准化

一、min-max 标准化 (Min-Max Normalization)

也称为离差标准化,是对原始数据的线性变换,使结果值映射到[0 - 1]之间。转换函数如下:

x_new = (x - min)/(max - min)

二、Z-score 标准化方法

这种方法给予原始数据的均值 (mean) 和标准差 (standard deviation) 进行数据的标准化。

经过处理的数据符合标准正态分布,即均值为 0,标准差为 1,转化函数为:

x_new = (x - mean) / variance
```

1, z-score 标准方法

```
#z-score标准化方法

def data_noraml1():
    nums = range(1, 21)
    mean = cal_mean(*nums)
    variance = cal_var(*nums)
    new_data = []
    for i in nums:
        value = (i - mean) / variance
        new_data.append(round(value, 2))
    return new_data
```

执行结果

```
[-0.29, -0.26, -0.23, -0.2, -0.17, -0.14, -0.11, -0.08, -0.05, -0.02, 0.02, 0.05, 0.08, 0.11, 0.14, 0.17, 0.2, 0.23, 0.26, 0.29]
```

2.min-max 标准化

```
#min-max标准化方法

def data_noraml2():
    nums = range(1, 21)
    mean = cal_mean(*nums)
    variance = cal_var(*nums)
    min = np.max(nums)
    max = np.min(nums)
    max_min = max - min
    new_data = []
    for i in nums:
        value = (i - min) / max_min
        new_data.append(round(value, 2))
    return new_data
```

执行结果:

[1, 0.94, 0.89, 0,83, 0,79 0.73 0.68 0.63 0.57 0.53 0.46 0.41 0.37 0.32 0.26

0.20 0.16 0.11

```
#数据数值化
"""
数据数值化
1.one-hot 编码
2.排序编码
"""
```

one-hot 编码

执行结果为:

```
rainy的one-hot编码如下:[1, 0, 0, 0, 0] sunny的one-hot编码如下:[0, 1, 0, 0, 0] snowy的one-hot编码如下:[0, 0, 1, 0, 0] windy的one-hot编码如下:[0, 0, 0, 1, 0] cold的one-hot编码如下:[0, 0, 0, 0, 1]
```

排序编码:

执行结果:

```
[1, 2, 3, 4, 1, 2, 4, 3]
```

4. 实现两种数据离散化,数据数值化,数组归一化方法

实现两种相似度计算方法

1.数值型(欧氏距离)

```
#.数值型相似度实现(欧式距离)

def numercial_type():
    nums_one = [7,87,41,32,17,8,97,45,12,31,48,4]
    nums_two = [13,6,9,7,54,8,41,23,1,64,54,5]
    #对数据做一个归一化处理
    normalData_one = data_noraml2(*nums_one)
    normalData_two = data_noraml2(*nums_two)
    lens = len(nums_one)
    dis = [normalData_one[i]-normalData_two[i] for i in range(lens)]
    sum = 0
    for x in dis:
        sum += x**2
    return round(m.sqrt(sum),2)
```

2. 标称型 *dp*

执行结果为:

0.29